

DEVOPS E ARQUITETURA CLOUD

FASE 2 | AULA 07 -
**ESCALABILIDADE
AUTOMÁTICA DA
APLICAÇÃO**

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS	5
MERCADO, CASES E TENDÊNCIAS	8
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

O QUE VEM POR AÍ?

Nesta aula, exploraremos um dos pilares mais críticos do Kubernetes em ambientes de produção: a escalabilidade automática. Em um mundo onde a demanda por aplicações pode variar drasticamente em questão de minutos, a capacidade de ajustar automaticamente os recursos computacionais não é mais um luxo, mas uma necessidade estratégica para garantir performance, disponibilidade e eficiência de custos.

Você aprenderá a arquitetura complexa por trás do Horizontal Pod Autoscaler (HPA), Vertical Pod Autoscaler (VPA) e Cluster Autoscaler (CA), entendendo não apenas como configurá-los, mas como empresas como Netflix e Uber utilizam essas tecnologias para gerenciar picos de demanda que podem chegar a milhões de requisições por segundo.

Prepare-se para mergulhar em métricas customizadas, políticas de escalonamento inteligente e as melhores práticas do mercado para implementar autoscaling em ambientes de missão crítica.

HANDS ON

Neste Hands On, vamos implementar um sistema completo de autoscaling multi-camadas para uma aplicação web simulando cenários reais de produção.

Etapas Detalhadas do Exercício:

Configuração do Ambiente de Métricas

- Implementação do Prometheus Stack para Métricas Customizadas;
- Configuração de HPA Avançado com Múltiplas Métricas;
- Implementação do Vertical Pod Autoscaler;
- Configuração do Cluster Autoscaler para AWS;
- Testes de Carga e Validação;
- Dashboard de Monitoramento Completo.

SAIBA MAIS

Arquitetura Profunda do Autoscaling no Kubernetes

A Evolução do Autoscaling em Ambientes Cloud Native

O autoscaling no Kubernetes representa a convergência de várias disciplinas: monitoramento, orquestração de containers, e economia de cloud computing. A jornada evolutiva inclui:

Gerações de Autoscaling:

1ª Geração: scaling baseado apenas em CPU/Memória.

2ª Geração: métricas customizadas e application-aware scaling.

3ª Geração: predictive scaling com machine learning.

4ª Geração: event-driven e serverless architectures.

Horizontal Pod Autoscaler (HPA) - Arquitetura Detalhada

Componentes do Sistema HPA:

HPA Controller → Metrics API → Metrics Server/Prometheus Adapter → cAdvisor → Kubelet

Algoritmo de Escalonamento:

```
// Pseudocódigo do algoritmo HPA
desiredReplicas = ceil[currentReplicas * (currentMetricValue / desiredMetricValue)]
```

Considerações de Estabilização:

- **Stabilization Window:** previne flapping (oscilação rápida).
- **Scaling Policies:** cControla velocidade de scaling up/down.
- **Multiple Metrics:** lógica de combinação (AND/OR conditions).

Vertical Pod Autoscaler (VPA) - Otimização de Recursos

Arquitetura do VPA:

Recommender: analisa histórico e sugere recursos.

Updater: Executa atualizações nos Pods.

Admission Controller: Aplica recommendations no deployment.

Modos de Operação:

Off: apenas recomenda, não executa.

Initial: aplica apenas na criação do Pod.

Auto: atualiza automaticamente (requer recriação).

Recreate: similar ao Auto, mas mais agressivo.

Cluster Autoscaler - Dimensionamento de Infraestrutura

Mecanismo de Decisão do CA:

- **Scale Up:** pods pendentes por falta de recursos.
- **Scale Down:** nós subutilizados por período configurado.
- **Node Groups:** diferentes tipos de instâncias para diferentes workloads.

Arquitetura Híbrida para Workloads Event-Driven

```
apiVersion: keda.sh/v1alpha1
kind: ScaledObject
metadata:
  name: rabbitmq-scaledobject
spec:
  scaleTargetRef:
    name: worker-deployment
  triggers:
    - type: rabbitmq
      metadata:
        host: amqp://localhost:5672
```

```
queueName:  
queueLength: "5"
```

```
hello
```

Scalers Suportados:

- **Message Queues:** Kafka, RabbitMQ, AWS SQS.
- **Databases:** PostgreSQL, MySQL, Redis.
- **Cloud Services:** AWS CloudWatch, Azure Monitor.
- **Custom Metrics:** HTTP endpoints, gRPC.

Estratégias de Autoscaling para Diferentes Tipos de Aplicações

Web Applications (Stateless):

- **Primary Metric:** HTTP requests per second.
- **Secondary Metrics:** CPU, memory, response time.
- **Scaling Pattern:** Rapid scale-up, gradual scale-down.

Data Processing (Batch Jobs):

- **Primary Metric:** Queue length (RabbitMQ, Kafka).
- **Scaling Pattern:** Scale to zero when idle.

Microservices (Complex Dependencies):

- **Primary Metric:** Business metrics (orders/sec, users active).
- **Considerations:** Cascading scaling across services.

Databases (Stateful):

- **Challenges:** Data replication, consistency.
- **Solutions:** Read replicas, sharding-aware scaling.

MERCADO, CASES E TENDÊNCIAS

Panorama do Mercado de Autoscaling

A **adoção empresarial** de ferramentas de escalabilidade no Kubernetes tem se intensificado: atualmente, 82% das empresas utilizam HPA (Horizontal Pod Autoscaler) em ambientes de produção, enquanto 45% implementam VPA (Vertical Pod Autoscaler) para otimização de recursos. Além disso, 67% recorrem ao Cluster Autoscaler em clouds públicas, e a adoção de KEDA (Kubernetes Event-driven Autoscaling) cresceu 120% nos últimos 18 meses, evidenciando a crescente demanda por soluções que garantam performance e eficiência de recursos em ambientes dinâmicos.

Impactos Econômicos:

- Redução média de 40% em custos de infraestrutura cloud.
- Melhoria de 99.95% no SLA de disponibilidade.
- Otimização de 60% na utilização de recursos.

Cases de Sucesso em Larga Escala

Netflix: Streaming Global com Picos Extremos

- **Desafio:** 250+ milhões de usuários, picos de 50M+ concorrentes.
- **Solução:** HPA multi-métricas + Cluster Autoscaler multi-region.
- **Arquitetura:**
 - Métricas: Concurrent streams, bitrate adaptation, buffer health.
 - Scaling: Predictive baseado em histórico de feriados.
 - Resultado: 99.99% uptime durante eventos como Super Bowl.

Uber: Demand-Based Scaling Geográfico

- **Contexto:** demanda variável por cidade, hora, eventos especiais.
- **Implementação:** custom metrics baseado em ride requests por região.

- **Inovação:** Machine learning para prever demanda por área geográfica.
- **Impacto:** 30% redução em custos de infraestrutura com melhor SLA.

Spotify: Music Streaming com Padrões Complexos

- **Padrões de Uso:** picos matinais, evening relaxation, weekend discovery.
- **Solução:** HPA com métricas de audio streaming quality.
- **Metrics Custom:** concurrent listeners, track skip rates, buffer events.
- **Resultado:** 40% melhor qualidade de streaming durante picos.

Tendências Emergentes 2024

AI-Powered Predictive Autoscaling

- Machine Learning para antecipar demanda.
- Integration com forecasting models.
- Cost-aware scaling decisions.

Serverless Kubernetes Platforms

- Knative serving para scale-to-zero.
- Event-driven architectures.
- Pay-per-use pricing models.

Multi-Cluster Autoscaling

- Federation across multiple clusters.
- Cross-cloud resource optimization..
- Geographic load distribution.

FinOps Integration

- Real-time cost visibility durante scaling.
- Budget-aware autoscaling policies.
- Showback/chargeback automation.

Green Computing Initiatives

- Carbon-aware scheduling.
- Energy-efficient scaling algorithms.
- Sustainable resource utilization.

Security-First Autoscaling

- Zero-trust scaling policies.
- Security context propagation.
- Compliance-aware resource allocation.

EMSE

O QUE VOCÊ VIU NESTA AULA?

Nesta aula sobre escalabilidade automática no Kubernetes, exploramos diversos aspectos essenciais. Na seção de arquiteturas, analisamos os mecanismos internos do HPA, VPA e Cluster Autoscaler, os algoritmos de decisão e políticas de estabilização e a integração com sistemas de métricas e monitoramento. Em implementação enterprise, abordamos configurações avançadas para ambientes de produção, estratégias para diferentes tipos de aplicações e técnicas de monitoramento e troubleshooting de autoscaling.

A seção de casos reais e melhores práticas trouxe patterns de scaling para web apps, microservices e data processing, além de considerações sobre custo e performance e a integração com práticas de FinOps e Green IT.

REFERÊNCIAS

GITHUB. **Cluster Autoscaler.** Disponível em: <https://github.com/kubernetes/autoscaler/tree/master/cluster-autoscaler> . Acesso em: 26 set. 2025.

GITHUB. **Metrics Server.** Disponível em: <https://github.com/kubernetes-sigs/metrics-server> Acesso em: 25 set. 2025.

GTHUB. **Vertical Pod Autoscaler.** Disponível em: <https://github.com/kubernetes/autoscaler/tree/master/vertical-pod-autoscaler>. Acesso em: 26 set. 2025.

KUBERNETES. **Horizontal Pod Autoscaler.** Disponível em: <https://kubernetes.io/docs/tasks/run-application/horizontal-pod-autoscale> Acesso em: 26 set. 2025.

PALAVRAS-CHAVE

Autoscaling. HPA. VPA.

EMSE



POSTECH