

DEVOPS E ARQUITETURA CLOUD

FASE 2 | AULA 04 -

CDNS E PERFORMANCE GLOBAL

SUMÁRIO

O QUE VEM POR AÍ?	3
HANDS ON	4
SAIBA MAIS.....	5
MERCADO, CASES E TENDÊNCIAS	10
O QUE VOCÊ VIU NESTA AULA?	11
REFERÊNCIAS.....	12

EMANIP

O QUE VEM POR AÍ?

Até agora, construímos uma aplicação robusta, com uma arquitetura de software escalável, rodando em uma frota de servidores gerenciada por um LoadBalancer inteligente. Nossos servidores estão em um data center no Brasil e funcionam perfeitamente para os usuários locais. Mas, o que acontece quando um cliente em Lisboa, Tóquio ou Nova York tenta acessar nosso site? A física é implacável. A distância geográfica impõe um custo inevitável: a latência, o tempo que um pacote de dados leva para viajar o mundo pelos cabos submarinos... não importa quão potente seja nosso servidor, a experiência para esse usuário global será lenta.

Nesta aula, vamos romper as barreiras geográficas. Apresentaremos a tecnologia que permite que gigantes como a Netflix, Amazon e Google entreguem conteúdo em altíssima velocidade para qualquer pessoa no planeta, como se houvesse um servidor em cada bairro. Vamos desvendar a "mágica" das CDNs (Content Delivery Networks) ou Redes de Entrega de Conteúdo. Você descobrirá que elas são muito mais do que um simples "cache" e representam uma camada estratégica fundamental para a performance, a segurança e a escalabilidade de qualquer aplicação moderna com ambições globais.

HANDS ON

Nosso hands-on será uma exploração conceitual e visual de uma das CDNs mais populares do mercado, o AmazonCloudFront. O objetivo é desmistificar a configuração de uma CDN e mostrar como os conceitos teóricos que discutiremos se traduzem em configurações práticas no painel de um provedor de nuvem. As videoaulas que acompanham este material guiarão você passo a passo por essa jornada.

Começaremos navegando pelo console da AWS para criar uma "distribuição" do CloudFront. Apontaremos para os conceitos-chave do processo: a definição do "Origin", que é o nosso servidor de aplicação onde o conteúdo original reside; a configuração dos "Behaviors", que são as regras que ditam como o CloudFront deve tratar diferentes tipos de requisições e por quanto tempo deve armazenar os arquivos em cache; e, por fim, o nome de domínio que a CDN nos fornece para que possamos apontar nossos usuários para ela.

Na segunda parte, agiremos como detetives de performance. Utilizando as ferramentas de desenvolvedor do navegador, vamos inspecionar os cabeçalhos (headers) de uma resposta HTTP que foi entregue por uma CDN. Procuraremos por cabeçalhos específicos como Cache-Control, que contém as diretivas de cache enviadas pela origem, e X-Cache, que nos diz o veredito da CDN: "Hit" (o conteúdo foi entregue pelo cache da borda) ou "Miss" (a CDN precisou buscar o conteúdo na origem). Este exercício prático tornará tangível o funcionamento do cache e solidificará seu entendimento sobre como verificar e depurar a performance de uma CDN.

SAIBA MAIS

O principal inimigo da experiência do usuário em uma aplicação global é a **latência**. Ela é determinada por duas leis físicas imutáveis: a velocidade da luz e a distância geográfica. Para um usuário na Europa acessar um servidor no Brasil, os dados precisam viajar milhares de quilômetros por cabos de fibra óptica submarinos, resultando em um atraso perceptível (geralmente centenas de milissegundos) antes mesmo que o servidor comece a processar a requisição. Para resolver este problema fundamental, foi criada a **CDN (Content Delivery Network)**. Uma CDN é uma rede globalmente distribuída de servidores proxy, estrategicamente localizados em pontos de troca de tráfego da internet (IXPs) ao redor do mundo. Esses locais são chamados de **Pontos de Presença (PoPs)** ou **Edge Locations**. O objetivo da CDN é simples: armazenar uma cópia do conteúdo da sua aplicação o mais perto possível do usuário final, reduzindo drasticamente a distância que os dados precisam viajar.




Figura 1 - Edge Location

Fonte: <https://www.geeksforgeeks.org/devops/amazon-web-services-introduction-to-cloudfront-cdn/> (2023)

O funcionamento de uma CDN se baseia em dois mecanismos principais que trabalham em conjunto: a **geolocalização via DNS** e o **Edge Caching**. Quando um usuário tenta acessar seu site (ex: *www.minhaempresa.com*), a primeira etapa é uma consulta DNS para traduzir esse nome em um endereço IP. Em uma configuração com CDN, essa consulta não vai para um servidor DNS comum. Ela é

direcionada para o sistema de DNS inteligente da CDN, que identifica a localização geográfica do usuário (com base no seu endereço IP) e, em vez de retornar o IP do seu servidor de origem no Brasil, ele retorna o endereço IP do PoP mais próximo daquele usuário.




Figura 2 - Geolocalização e Edge Chaching

Fonte: <https://awsfundamentals.com/blog/aws-edge-locations> (2023)

Uma vez direcionado para o PoP mais próximo (por exemplo, um usuário em Paris é enviado para o PoP de Paris), o segundo mecanismo entra em ação: o Edge Caching. O PoP de Paris verifica se possui uma cópia do conteúdo solicitado (ex: uma imagem ou um arquivo CSS) em seu cache local. Se for a primeira vez que alguém naquela região solicita aquele conteúdo, ocorre um "Cache Miss": o PoP de Paris se conecta ao seu servidor de origem no Brasil para buscar o arquivo, o entrega para o usuário e, crucialmente, armazena uma cópia em seu próprio cache. Quando o próximo usuário em Paris, ou em qualquer lugar próximo, solicitar o mesmo arquivo, ocorrerá um "Cache Hit": o PoP de Paris servirá o arquivo instantaneamente a partir de seu cache local, sem precisar cruzar o oceano novamente. O resultado é uma redução drástica na latência e uma experiência de usuário muito mais rápida.




Figura 3 - Cache hit e Cache Miss

Fonte: <https://codigosimples.net/2025/03/24/cache-hit-ratio-como-uma-simples-metrica-pode-revolucionar-sua-arquitetura/> (2025)

Gerenciar o que é armazenado em cache e por quanto tempo é uma tarefa crítica. Esse controle é feito primariamente por cabeçalhos HTTP que o seu servidor de origem envia junto com o conteúdo. O cabeçalho mais importante é o Cache-Control. Por meio de suas diretivas, você informa à CDN (e ao navegador do usuário) como o cache deve se comportar. A diretiva mais comum é a max-age, que define o TTL (Time to Live), o tempo em segundos que o arquivo pode ser considerado "fresco" e servido diretamente do cache sem revalidação. Por exemplo, Cache-Control: public, max-age=3600 instrui o cache a armazenar o arquivo por uma hora. Quando esse tempo expira, o cache considera o arquivo "velho" (stale) e, na próxima requisição, irá revalidá-lo com o servidor de origem. Se o arquivo não mudou, a origem responde com um "304 NotModified" e a CDN continua a servir a versão que já possui, apenas renovando seu TTL.




Figura 4 - Modificação do Conteúdo e alteração do Cache-Control

Fonte: <https://blog.jonathanlau.io/posts/how-to-use-cache-control-headers/> (2024)

Mas e se você precisar atualizar um arquivo urgentemente, como um bug fix em um arquivo JavaScript, e não puder esperar o TTL expirar? Para isso, as CDNs oferecem um mecanismo de invalidação (ou purging). Pelo painel de controle ou de uma API, você pode enviar um comando para a CDN, ordenando que ela remova à força um ou mais arquivos de todos os seus caches ao redor do mundo. Na próxima requisição, a CDN será forçada a buscar a nova versão na origem. A invalidação é uma ferramenta poderosa, mas deve ser usada com critério, pois pode ter custos associados e, se usada em excesso, pode reduzir a eficiência do cache.

É um erro comum pensar que CDNs servem apenas para "assets" estáticos como imagens, CSS e JavaScript. CDNs modernas são perfeitamente capazes de escalar a entrega de APIs. Respostas de requisições GET que não mudam com frequência (como o catálogo de produtos de um e-commerce) podem ser cacheadas na borda da mesma forma que uma imagem, reduzindo drasticamente a carga nos seus servidores de aplicação e bancos de dados. Os principais players do mercado, como AmazonCloudFront, Akamai e Fastly, oferecem funcionalidades robustas tanto para a entrega de conteúdo estático, quanto dinâmico.

A posição estratégica da CDN, como o primeiro ponto de contato para todo o tráfego da sua aplicação, a tornou um hub ideal para aplicar camadas de segurança e performance. A integração de uma CDN com um WAF (Web Application Firewall) permite que ataques comuns, como SQL Injection e Cross-Site Scripting (XSS), sejam detectados e bloqueados na borda, antes mesmo que cheguem à sua infraestrutura. Além disso, a negociação de uma conexão segura HTTPS (o handshake TLS) é um processo computacionalmente intensivo. As CDNs podem realizar o TLS Offload, lidando com essa negociação em seus servidores de borda, que são altamente otimizados para essa tarefa, e estabelecendo uma conexão segura e otimizada com seu servidor de origem, aliviando a carga de CPU da sua aplicação.




Figura 5 - WAF em conjunto com CDN

Fonte: <https://learn.microsoft.com/pt-br/azure/web-application-firewall/cdn/cdn-overview> (2025)

Para que tudo isso funcione em escala global, as CDNs operam em um nível profundo da infraestrutura da internet. Elas utilizam o protocolo BGP (Border Gateway Protocol), o sistema de roteamento da internet, de forma proativa para anunciar as rotas mais eficientes para seus PoPs. Além disso, estabelecem acordos de peering, que são conexões diretas e privadas com grandes provedores de internet, para criar "atalhos" e reduzir o número de saltos que os dados precisam dar, diminuindo ainda mais a latência. Por fim, a observabilidade da entrega de conteúdo é crucial. Os painéis das CDNs fornecem métricas essenciais como o Cache Hit Ratio (a porcentagem de requisições servidas pelo cache, a métrica mais importante da eficiência de uma CDN), a economia de banda, a latência de resposta e as taxas de erro, permitindo que você monitore e otimize continuamente a performance global da sua aplicação.

MERCADO, CASES E TENDÊNCIAS

A tecnologia de CDN está em constante evolução, movendo-se de simples redes de cache para plataformas de computação sofisticadas na borda da internet.

Case: A Estratégia de Lançamento da Indústria de Games

Grandes lançamentos de jogos, como um novo patch para "Fortnite" ou "League of Legends", envolvem a distribuição de dezenas de gigabytes de dados para milhões de jogadores simultaneamente. Fazer isso a partir de um data center central seria impossível. As empresas de games utilizam CDNs de forma massiva para pré-posicionar esses arquivos nos PoPs ao redor do mundo dias antes do lançamento. Quando o lançamento ocorre, os jogadores baixam o conteúdo do servidor da CDN mais próximo, garantindo uma experiência de download rápida e evitando o colapso dos servidores de origem.

Tendência: A Revolução do Edge Computing

A tendência mais quente no mercado de CDNs é a computação de borda (Edge Computing). Em vez de apenas armazenar conteúdo estático, as CDNs agora permitem que os desenvolvedores executem código diretamente nos PoPs. Serviços como AWS Lambda@Edge e CloudflareWorkers permitem rodar funções que podem modificar requisições e respostas em trânsito. Casos de uso incluem renderização de páginas no servidor mais próximo do usuário, execução de testes A/B, manipulação de imagens em tempo real e até mesmo a execução de lógicas de autenticação na borda, tudo com latência ultrabaixa.

Notícia: CDNs e a Aceleração de Conteúdo Dinâmico

Tradicionalmente, conteúdo dinâmico e não cacheável ainda sofria com a latência da conexão até o servidor de origem. Notícias recentes e lançamentos de produtos de empresas como a Akamai e a Fastly focam em "DynamicContentAcceleration". Usando técnicas de otimização de TCP/IP e roteamento inteligente (baseado em BGP e peering), as CDNs agora conseguem acelerar até mesmo o conteúdo que não pode ser cacheado, encontrando o caminho mais rápido e estável na internet entre o usuário, a borda e a origem.

O QUE VOCÊ VIU NESTA AULA?

Nesta aula, rompemos as barreiras geográficas da escalabilidade. Você aprendeu que a latência é o principal adversário da performance global e que as CDNs são a solução para combatê-la, utilizando geolocalização via DNS e Edge Caching para aproximar o conteúdo do usuário. Vimos como podemos controlar o comportamento do cache por meio de cabeçalhos HTTP como o Cache-Control e como forçar atualizações com a invalidação. Descobrimos que as CDNs não servem apenas para assets, mas também para escalar a entrega de APIs. Por fim, exploramos o papel estratégico da CDN como uma plataforma de segurança, com a integração de WAFs, e de performance, com TLS Offload, e como a computação de borda (Edge Computing) está revolucionando o que é possível fazer mais perto do usuário.

REFERÊNCIAS

AWS. **AmazonCloudFrontDeveloperGuide**. Amazon Web Services Documentation. Disponível em: <https://docs.aws.amazon.com/AmazonCloudFront/latest/DeveloperGuide/Introduction.html>. Acesso em: 28 ago. 2025.

GRIGORIK, I. **High Performance Browser Networking**. Sebastopol: O'Reilly Media, 2013. Disponível em: <https://hpbn.co/>. Acesso em: 28 ago. 2025.

THE CLOUDFLARE BLOG. **What is a CDN? | How do CDNs work?**. Disponível em: <https://www.cloudflare.com/learning/cdn/what-is-a-cdn/>. Acesso em: 28 ago. 2025.

PALAVRAS-CHAVE

CDN. POP. Edge Location. Edge Caching. Elasticidade. Cache Hit.

EMSE

The background is a dark, teal-colored abstract digital space. It features a network of thin, glowing white lines that connect various nodes and shapes. Some nodes are small circles, while others are larger, rectangular shapes resembling computer components or data blocks. The overall effect is a sense of a complex, interconnected digital system or network.

POSTECH